
스마트 제조 AI Agent 해커톤 2025

MVP 기획서

팀명	노동조합
프로젝트명	SmartFlow

팀명	노동조합
팀원	정주환, 박준수
프로젝트명	SmartFlow
세부 주제	LLM 기반 Multi-Agent 협상을 통한 다단계 제조 공정의 사전 품질 예측 및 자율 조정 시스템
한줄소개	본 프로젝트는 스마트 제조 환경에서 공정 간 품질 연쇄 효과를 사전에 예측하고, LLM Agent들이 과거 작업 이력(RAG)을 참조하여 추론 및 협상을 통해 공정 파라미터를 자율 조정하는 시스템입니다.

2. 문제 정의 (Problem Definition)

- ✓ 공정 간 품질 정보가 단절되어 상위 공정의 문제가 하위 공정에서 뒤늦게 발견됨
- ✓ 불량 원인을 최종 공정에서야 확인하여 재작업·폐기 비용이 크게 증가함
- ✓ 각 공정이 개별적으로 운영되어 공정 간 영향도(연쇄 효과)를 파악하지 못함
- ✓ 품질 예측 모델이 있어도 ‘왜’와 ‘어떻게 조정해야 하는지’를 알려주지 못해 의사결정 어려움

3. 제안 솔루션 개요 (Solution Overview)

3.1 제안하는 AI Agent 시스템의 전체 구조

본 과제에서 제안하는 **CPQC-MAS**는 기존의 단순 수치 예측 머신러닝(ML) 모델의 한계를 넘어, LLM(거대언어모델) 기반의 추론과 **RAG(검색 증강 생성)** 기술을 결합한 다중 에이전트 협업 시스템입니다.

시스템은 크게 **데이터 수집 및 이상 감지**, **품질 연쇄 영향 예측**, 사례 기반 추론 및 협상의 3단계 레이어로 구성됩니다. 공정 간 파편화된 데이터를 통합하고, ML이 예측한 수치를 LLM이 언어적으로 해석하여 능동적으로 공정 파라미터를 사전 조정하는 것이 핵심 구조입니다.

3.2 에이전트 구성

본 시스템은 역할이 명확히 분리된 4가지 핵심 에이전트로 구성됩니다.

1. **Process Monitor Agent (감시자)**: 각 공정의 센서 데이터를 실시간으로 수집하고, 1차적인 이상 징후를 포착하여 예측 에이전트에게 전달합니다.
2. **Quality Cascade Predictor (예측자)**: ML/DL 모델(Multi-scale CNN 등)을 활용해 현재 공정의 변동이 후속 공정에 미칠 품질 영향을 수치적으로 계산합니다.
3. **RAG-enabled Negotiation Agent (협상자)**: 핵심 에이전트로, ML의 예측값을 언어적으로 해석하고 RAG를 통해 과거 유사 작업 일지와 성공/실패 사례를 검색합니다. 이를 바탕으로 최적의 조정안을 추론하고 타 공정 에이전트와 협상합니다.
4. **Coordinator Agent (조정자)**: 전체 생산 목표(품질, 비용, 납기)를 고려하여 에이전트 간의 협상 결과를 최종 승인하거나 반려합니다.

3. 제안 솔루션 개요 (Solution Overview)

3.3 에이전트 별 역할 및 상호작용 방식

에이전트들은 **LangGraph** 기반의 순환 구조를 통해 실시간으로 메시지를 교환하며 유기적으로 작동합니다.

- 해석 및 추론 :** ML 모델이 "용접 강도 5% 저하"라는 수치를 예측하면, Negotiation Agent는 RAG를 통해 "과거 전류 증강 시 균열 발생 이력"을 찾아냅니다. 이를 통해 단순 수치 보정이 아닌, 맥락을 고려한 대안을 수립합니다.
- 협상 메커니즘 :** 선행 공정 에이전트가 품질 확보를 위해 파라미터 조정을 제안하면, 후속 공정 에이전트는 자신의 생산성 및 부하 상황을 고려하여 수락하거나 대안을 제시합니다.
 - 예: "품질을 위해 속도를 줄이자" (Agent A) ↔ "납기 준수를 위해 압력을 높이는 것으로 타협하자" (Agent B)

3.4 전체 시나리오 요약 (MVP: 프레스-용접 공정)

본 솔루션이 적용된 실제 작동 시나리오는 다음과 같습니다.

- 감지:** 프레스 공정의 Monitor Agent가 두께 편차(+0.02mm) 발생을 감지합니다.
- 예측:** Predictor가 해당 편차로 인해 후속 용접 공정에서 강도가 약 4.8% 저하될 것임을 예측합니다.
- 검색 및 추론:** Negotiation Agent가 RAG DB에서 "과거 유사 편차 발생 시 전류만 높였다가 비드 균열이 발생한 사례"를 찾아냅니다. 이를 바탕으로 '전류 증강' 대신 '속도 감속 및 압력 미세 조정'이라는 새로운 전략을 추론합니다.
- 협상:** 용접 공정 Agent와 협상을 통해 생산 일정에 차질이 없는 범위 내에서 속도 5% 감소 및 압력 2% 증가 합의안을 도출합니다.
- 조치 및 피드백:** Coordinator 승인 후 파라미터가 자동 조정되며, 결과(품질 회복 90%)는 다시 RAG 데이터베이스에 성공 사례로 저장되어 시스템을 강화합니다.

4. 주요 기능 정의 (Key Features)

4.1 솔루션 핵심 기능 구성

본 솔루션은 제조 현장의 문제를 해결하기 위해 다음의 3가지 핵심 기능을 유기적으로 통합하여 제공합니다.

① 공정 간 품질 연쇄 영향 예측

- **기능 설명:**
 - 선행 공정(예: 프레스)에서 발생한 미세한 오차가 후속 공정(예: 용접, 조립)에 도달했을 때 증폭될 품질 저하 수치를 예측합니다.
 - 단일 공정 내의 이상 탐지가 아닌, 공정 간 인과관계를 분석하여 '나비 효과'를 사전에 차단합니다.
- **해결하는 문제:**
 - 개별 공정은 허용 오차 범위 내에 있더라도, 누적된 오차로 인해 최종 제품이 불량이 되는 문제를 해결합니다.

② RAG 기반 맥락 인식 및 원인 추론

- **기능 설명:**
 - ML 모델이 예측한 수치 데이터("강도 5% 저하")를 LLM이 입력 받아, **RAG(검색 증강 생성)** 기술로 과거 작업 일지와 불량 사례 DB를 검색합니다.
 - 단순히 수치를 맞추는 것이 아니라, "과거에 유사한 상황에서 A 조치를 했다가 실패했으니, 이번엔 B 조치를 해야 한다"는 식의 언어적 추론을 수행합니다.
- **해결하는 문제:**
 - 숙련된 엔지니어의 경험(암묵지)이 데이터화되지 않아 발생하는 **반복적인 시행착오와 유사 불량 재발**을 방지합니다.

4. 주요 기능 정의 (Key Features)

③ 에이전트 간 자율 협상 및 파라미터 최적화

- **기능 설명:**
 - 각 공정을 대변하는 AI 에이전트들이 서로의 상황(부하, 납기, 품질)을 공유하고 대화하여 최적의 파라미터를 합의합니다.
 - **Trade-off 조율:** 품질을 위해 속도를 늦출 것인지, 납기를 위해 다른 보정값을 찾을 것인지 실시간으로 협상합니다.
- **해결하는 문제:**
 - 부서(공정) 간 소통 부재로 인한 **부분 최적화의 한계**를 극복하고 전체 공정 효율을 높입니다.

4.2 본선 MVP(Minimum Viable Product) 구현 범위

대회 본선 및 시연을 위해 전체 시스템 중 가장 효과적인 시나리오를 선정하여 집중 구현합니다.

구분	MVP 구현 핵심 내용	비고
대상 공정	2단계 공정 연결 (프레스 → 용접)	데모의 명확성을 위해 축소
시나리오	두께 편차 발생 시 → 용접 파라미터 자동 재조정	구체적 Pain Point 해결
구현 기능	1. Data Ingestion: 가상 센서 데이터 생성 및 이상 감지 2. Reasoning: RAG를 통한 과거 실패 사례 검색 3. Negotiation: 에이전트 간 채팅 로그(협상 과정) 시각화	LangGraph 활용

5. 데이터 활용 계획 (Data Plan)

데이터셋 명	데이터 유형	주요 활용 방법 (시스템 내 역할)	비고 및 한계
Multi-Stage Continuous-Flow Manufacturing Process	공정 센서 데이터, 품질 측정 데이터	2단계 연속 공정(Stage 1 → Stage 2)의 품질 연쇄 예측 모델 학습에 완벽 적합함. Stage 1은 프레스 공정, Stage 2는 용접 공정으로 매핑하여 Agent 모니터링 및 예측에 활용함.	샘플 수 14,088개로 처리 용이함. 2단계만 제공되므로 3단계 확장은 SimPy 시뮬레이션으로 보완이 필요함.
Bosch Production Line Performance	공정 센서 데이터, 품질 측정 데이터	3단계 공정 A→B→C 연쇄 모델링을 포함한 다단계 조립 라인 확장 전략에 활용함. Station Group을 프레스/용접/도장 공정으로 매핑하여 활용할 계획임.	대용량(14.3 GB)으로 메모리 및 전처리 전략 (샘플 수 축소 등)이 필요함.
SECOM (Semiconductor Manufacturing)	공정 센서 데이터	단일 Agent의 품질 예측 모델 학습 및 불량률 6.6%인 데이터의 클래스 불균형 처리 연습에 활용함.	공정 단계 구분이 불명확하여 다단계 연쇄 예측에는 부적합함.
Steel Plates Faults	기하학적 특징 데이터	Press Monitor Agent의 결함 탐지 모델 학습에 제한적으로 활용하여 기하학적 특징으로부터 결함 예측 패턴을 학습함.	다단계 공정 데이터는 아님.

6. 기술 활용 계획 (Tech Plan)

기술 요소	활용 기술/프레임워크	역할 및 활용 방안	기술 성숙도/검증
LLM 추론 및 협상 (핵심)	GPT-4, Claude	ML 예측 수치를 언어적으로 해석하고, RAG 결과를 바탕으로 추론 (Reasoning)을 수행하여 최적의 사전 조정안을 제시합니다. Agent 간 협상 로직의 중심 역할을 수행합니다.	GPT-4, Claude 3.5 Sonnet 등은 현재 상용화 완료되어 있어 기술 성숙도가 높습니다.
RAG 시스템	LangChain, ChromaDB	과거 작업 일지, 불량/성공 사례, 도메인 지식을 검색하여 LLM의 맥락 인식 의사결정을 지원합니다. 불량 사례를 검색하여 위험 조치(예: 전류 증가)를 회피하는 근거를 제공합니다.	LangChain은 활발히 업데이트 중이며, ChromaDB는 v0.4.x 안정 버전으로 오픈소스 활성화도가 높습니다.
Multi-Agent 조율 (MAS)	LangGraph, AutoGen (대안)	Process Monitor, Predictor, Negotiation Agent 간의 순환 구조를 가진 복잡한 협상 워크플로우를 구현하고 State를 효율적으로 관리합니다. 공정 간 온라인 조율을 통해 전체 시스템 수율을 최적화하는데 활용됩니다.	LangGraph는 2024년 v0.2로 Production-ready 상태에 도달했습니다.
수치 예측 (ML/DL)	Multi-scale CNN, MEPN (가공 오류 전파 네트워크)	공정 A→B→C의 연쇄 품질 영향을 수치화하여 예측 결과를 Negotiation Agent에게 전달하는 도구(Tool) 역할을 담당합니다.	Multi-scale CNN 및 MEPN 개념은 학술적으로 실존이 확인되었으며, 대회 MVP에서는 간단한 룰 기반 시뮬레이션으로 대체될 수 있습니다.
데이터 및 IoT 인프라	MQTT Protocol, PostgreSQL	IoT 센서를 통해 실시간 공정 데이터를 수집하고 정규화하는 데 MQTT가 사용됩니다. PostgreSQL은 조정 이력 및 통합 공정 데이터를 저장하는 데이터베이스 구축에 활용됩니다.	일반적인 IoT/DB 기술 스택이며, 시스템의 기반 인프라를 구축합니다.

7. 사용자 시나리오/유즈케이스 (User Scenario)

7.1 주요 사용자 (Key Users)

본 시스템을 통해 가장 큰 가치를 얻게 될 핵심 사용자와 그들의 니즈는 다음과 같습니다.

- 품질 관리 엔지니어 (Quality Control Engineer):**
 - 역할:** 공정 데이터 모니터링 및 불량 원인 분석
 - 니즈:** 복잡한 공정 간 상관관계를 파악하여, 문제가 커지기 전에 원인을 찾고 예방 조치를 취하고 싶어 함.
- 생산 관리자 (Production Manager):**
 - 역할:** 전체 생산 일정 준수 및 라인 효율 관리
 - 니즈:** 품질 문제로 인한 라인 정지를 최소화하고, 불가피한 조정 시 생산성 저하를 방어할 수 있는 최적의 타협점을 찾고 싶어 함.

7.2 사용자 행동 흐름 (User Workflow)

사용자는 시스템의 제안을 최종 승인하는 '결정권자' 역할을 수행하며, 전체 흐름은 [감지 → 알림 → 검토 → 승인]의 4단계로 이루어집니다.

- 이상 감지 및 알림 (Alert):**
 - 시스템이 "프레스 공정의 미세 변동이 용접 품질 저하를 유발할 위험(85%)"을 감지하고 사용자에게 알림을 보냅니다.
- 원인 및 대안 분석 (Analysis):**
 - 사용자는 대시보드에서 AI가 제시한 '예측 근거(ML)'와 '과거 유사 실패 사례(RAG)'를 확인합니다.
- 협상 결과 검토 (Review):**
 - 에이전트들이 자율적으로 협상하여 도출한 '최적 파라미터 조정안(품질 vs 생산성 타협안)'을 검토합니다.
- 승인 및 실행 (Approval):**
 - 사용자가 "조정안 승인" 버튼을 클릭하면, 설비 파라미터가 즉시 변경되어 불량을 사전에 차단합니다.

7. 사용자 시나리오/유즈케이스 (User Scenario)

7.3 에이전트 간 협업이 드러나는 대표 시나리오 (Representative Scenario)

[상황] 프레스(Press) 공정의 두께 편차가 커져, 후속 용접(Welding) 공정에서 불량이 예상되는 상황.

단계	주체 (Agent)	협업 및 대화 내용 (Interaction Log)
1. 문제 제기	Press Agent	"현재 가공물의 두께 편차가 +0.02mm 발생했습니다. 후속 공정에 영향이 갈 수 있습니다."
2. 위험 예측	Predictor	"해당 편자는 용접 강도를 약 4.8% 떨어뜨릴 것으로 예측됩니다. 조치가 필요합니다."
3. 해결책 추론	Negotiation Agent	(RAG 검색 후) "과거 사례를 볼 때, 단순히 전류만 높이면 균열이 발생합니다. '전류 유지 + 용접 속도 5% 감속'을 제안합니다."
4. 이의 제기	Welding Agent	"속도를 5% 줄이면 시간당 생산량 목표를 맞출 수 없습니다. 거절합니다. 대안이 필요합니다."
5. 협상 및 합의	Negotiation Agent	"그렇다면 '압력을 2% 높이고 속도는 3%만 줄이는 절충안'은 어떨습니까? 품질 회복률 92%로 예상됩니다."
6. 최종 수락	Welding Agent	"생산 지연이 허용 범위 내입니다. 동의합니다. 사용자(Coordinator)에게 승인을 요청합니다."

8. 기대 효과 및 향후 확장성 (Expected Impact)

1-1. 정량적 기대 효과 (Quantitative Impact)

지표	목표 수치	근거 및 설명
최종 불량률 감소	15-20% ↓	다중 에이전트 시스템 현장 적용 결과의 평균치에 근거하며, 사전 예방 조치를 통해 불량률을 감소시키는 것이 목표입니다.
재작업 비용 절감	20-25% ↓	예측 기반 품질 관리 시스템을 도입한 기업들의 조사 결과에 근거하여, 최종 검사에서 불량률을 발견하여 전체 재작업/폐기하는 비효율을 제거합니다.
조기 문제 식별 속도 향상	35-45% ↑	실시간 모니터링 시스템과 기존 검사 방식을 비교한 연구 결과에 근거하여, 공정 A의 미세 오차가 B로 전파되기 전에 문제를 식별합니다.
예측 정확도	>90%	Supervised learning 기반 품질 예측 연구 메타 분석 결과에 근거하여, Quality Cascade Predictor의 예측 정확도 목표치입니다.
사전 조정 성공률	>85%	LLM Agent의 추론 및 RAG 검색을 통해 최적의 조정안을 도출하여 불량 발생을 성공적으로 막는 비율을 목표로 합니다.
협상 수령률	평균 3라운드 내 합의	Agent들이 효율적인 통신 프로토콜(LangGraph)을 사용해 실시간으로 trade-off를 해결하고 합의에 도달하는 속도입니다.

8. 기대 효과 및 향후 확장성 (Expected Impact)

1-2. 정성적 가치 및 혁신성 (Qualitative Impact)

본 프로젝트의 핵심 차별점은 LLM, RAG, MAS의 결합을 통해 기존 ML 시스템이 제공할 수 없었던 언어적 가치를 제공하는 것입니다.

1) 설명 가능성 (Explainability) 확보

: 시스템이 "왜 이 결정을 내렸는가"를 자연어로 설명할 수 있는 로그를 생성합니다. 이는 RAG를 통해 과거의 실패/성공 사례를 검색하고 이를 추론 근거로 제시하기 때문에 가능하며, 엔지니어의 시스템 신뢰도를 크게 향상시킵니다.

2) 사전 예방적 접근 (Preventive Approach)

: 기존 방식이 최종 검사 후 사후 대응이나 ML 예측 후 알림/권고에 그쳤다면, 본 제안은 LLM Agent의 추론 및 협상을 통해 문제 발생 전에 파라미터를 자동 조정하는 사전 예방적 조치를 취합니다.

3) 능동적 공정 간 협상 (Active Negotiation)

: 각 공정이 독립적으로 최적화되는 한계를 넘어, Agent들이 실시간으로 trade-off를 논의하여 전체 시스템 관점의 수율 최적화를 달성합니다.

4) 제조업 생성형 AI 실질적 활용

: 단순한 대화형 AI가 아니라, 수치 예측 결과를 해석하고 맥락을 인식하여 의사결정을 내리는 생성형 AI(LLM)의 실질적인 산업 활용 사례를 제시합니다.

8. 기대 효과 및 향후 확장성 (Expected Impact)

2. 확장성

1. 공정 범위 확장

: MVP Phase 1에서 검증된 2공정 연결(프레스 → 용접) 개념을 바탕으로, 전체 라인으로 점진적 확장이 가능합니다. Phase 2에서는 Bosch Production Line Performance와 같은 대용량 데이터를 활용하여 3단계 공정(프레스 → 용접 → 도장) 확장 모델링을 계획하고 있습니다.

2. 도메인 적용 확장

: 공정 데이터 및 텍스트 지식(RAG)만 교체하면 본 시스템의 핵심 로직(LLM 추론, Agent 협상)을 다른 제조 도메인(예: 식품 가공, 화학 공정)에도 적용할 수 있는 높은 범용성을 가집니다.

3. 시스템 통합

: LLM 기반의 유연한 아키텍처는 기존 제조 실행 시스템(MES)이나 전사적 자원 관리(ERP) 시스템과 API 연동을 통해 손쉽게 통합될 수 있으며, 단계적 확장을 통해 리스크를 최소화할 수 있습니다.

4. 기술 성숙도 기반 확장

: 핵심 기술인 LangGraph, LangChain, ChromaDB 등이 이미 안정 버전 또는 Production-ready 상태에 있어, 안정적인 기술 기반 위에 추가 기능을 구축하기 용이합니다.